Pokok Bahasan IV **Decision Tree with Python**

Kode Pokok Bahasan: TIK.RPL03.001.003.01

Deskripsi Pokok Bahasan:

Membahas bagaimana pembuatan Decision Tree pada dataset yang diberikan.

No	Elemen Kompetensi	Indikator Kinerja	Jml Jam	Hal
1	Menerapkan Decision Tree pada data Weather	1.1 Membuat Decision Tree menggunakan Library Scikit-	1	12
	Nominal dataset 1.	Learn menggunakan data Weather Nominal		
2	Menerapkan prediksi dan class pada Decision Tree data Weather Nominal dataset 2.	 1.1 Membuat Decision Tree menggunakan Library Scikit- Learn menggunakan data Weather Nominal 1.2 Membuat prediksi dari Decision Tree 1.3 Membuat class dari prediksi 	2	15

TUGAS PENDAHULUAN

Hal yang harus dilakukan dan acuan yang harus dibaca sebelum praktikum : Menginstal Anaconda Python pada PC masing-masing praktikan.

2. Menginstal Jupyter Notebook pada Anaconda Python pada PC masing masing praktikan.

DAFTAR PERTANYAAN

- 1. Apa itu decision tree?
- 2. Apa kegunaan Decision tree?
- 3. Adakah perbedaan dalam membuat decision tree antara R dan Python, berikan alasannya!
- 1. Decision tree merupakan suatu struktur yang digunakan untuk membantu proses pengambilan keputusan. Disebut sebagai "tree" karena struktur ini menyerupai sebuah pohon lengkap dengan akar, batang, dan percabangannya.
- 2. Manfaat utama dari penggunaan decision tree adalah kemampuannya untuk mem-break down proses pengambilan keputusan yang kompleks menjadi lebih simple, sehingga pengambil keputusan akan lebih menginterpretasikan solusi dari permasalahan.

3. Perbedaan yang sangat terlihat dari kedua bahasa ini adalah R digunakan untuk analisis statistik, sedangkan Python lebih general. Python adalah bahasa multipurpose, sama seperti C++ dan Java. Penggunaannya pun cenderung lebih mudah dipelajari, tak seperti R yang lebih kompleks.

TEORI SINGKAT

Decision tree adalah salah satu metode klasifikasi yang paling populer, karena mudah untuk diinterpretasi oleh manusia. Decision tree adalah model prediksi menggunakan struktur pohon atau struktur berhirarki.

Konsep dari pohon keputusan adalah mengubah data menjadi decision tree dan aturan-aturan keputusan. Manfaat utama dari penggunaan decision tree adalah kemampuannya untuk mem-break down proses pengambilan keputusan yang kompleks menjadi lebih simple, sehingga pengambil keputusan akan lebih menginterpretasikan solusi dari permasalahan.

Salah satu algoritma dari decision tree adalah CART (Classification and Regression Tree). Dimana metode ini merupakan gabungan dari dua jenis pohon, yaitu classification tree dan juga regression tree. Untuk memudahkan, berikut ilustrasi dari keduanya.

LAB SETUP

Hal yang harus disiapkan dan dilakukan oleh praktikan untuk menjalankan praktikum modul ini.

- 1. Menginstall library yang dibutuhkan untuk mengerjakan modul.
- 2. Menjalankan R Studio.

ELEMEN KOMPETENSI I

Deskripsi:

Menerapkan Decision Tree pada data Weather Nominal dataset 1.

Kompetensi Dasar:

Membuat Decision Tree menggunakan Library Scikit-Learn menggunakan data Weather Nominal.

Latihan 1.1.1

Penjelasan Singkat:

Pada latihan ini anda akan diminta untuk membangun decision tree menggunakan library yang disediakan oleh Python.

Langkah-Langkah Praktikum:

- 1. Buat file baru pada Jupyter Notebook atau Google Colab https://colab.research.google.com/
- 2. Letakkan file data yang digunakan pada direktori yang sama. Jika menggunakan Google Colab, upload data terlebih dahulu session storage. Klik upload to session storage seperti pada gambar di bawah.

Maka akan muncul seperti di bawah ini, pilihlah data prak4.csv pada penyimpanan anda, kemudian klik open.

Jika sudah makan akan muncul pada side bar seperti gambar berikut.

3. Import library python yang akan digunakan.

import pandas as pd

from sklearn.tree import DecisionTreeClassifier #import decision tree classifier from sklearn.model_selection import train_test_split #import train_test_split function

from sklearn import metrics

```
In [1]:
    import pandas as pd
    from sklearn.tree import DecisionTreeClassifier #import decision tree classifier
    from sklearn.model_selection import train_test_split #import train_test_split function
    from sklearn import metrics
```

4. Membaca data prak4.csv dengan metode read csv

data_namapraktikan = pd.read_csv("prak4.csv")
data namapraktikan.head()

```
In [5]: data_ibnu = pd.read_csv("D:/File Kuliah Semester 5/Penambangan Data/Prak-4/prak4.csv")
data_ibnu.head()
```

Out[5]:

	cuaca	suhu	kelembaban	berangin	bermain
0	cerah	panas	Tinggi	salah	tidak
1	cerah	panas	Tinggi	benar	tidak
2	berawan	panas	Tinggi	salah	ya
3	hujan	sejuk	Tinggi	salah	ya
4	hujan	dingin	Normal	salah	ya

Mengecek data secara umum

data_namapraktikan.info()

```
In [6]: data .info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 14 entries, 0 to 13
         Data columns (total 5 columns):
                      Non-Null Count Dtype
            Column
             -----
                          -----
         0 cuaca 14 non-null object
1 suhu 14 non-null object
2 kelembaban 14 non-null object
            berangin 14 non-null
                                           object
                         14 non-null
                                           object
             bermain
         dtypes: object(5)
         memory usage: 688.0+ bytes
```

- 6. Pada saat harus bekerja dengan kolom atau atribut bertipe kolom, maka data harus diubah dalam format numerik. Pada library sklearn.preprocessing tersedia dua metode untuk mengubah tipe data kategorikal menjadi data numerik yaitu label encoding dan one hot encoding.
 - 6.1. Import library sklearn untuk melakukan label encoding dan onehot encoding. Kemudian melakukan datapreprocessing menggunakan label encoding dan one hot encoding.

```
from numpy import array
from numpy import argmax
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OneHotEncoder
print(data namapraktikan.columns)
fiturs = ['cuaca', 'suhu', 'kelembaban', 'berangin']
labels encoder = LabelEncoder()
iobs encoder = OneHotEncoder(sparse=False)
data namapraktikan1 = data namapraktikan.copy(deep=True)
for fitur in fiturs:
  print(f'{fitur}:{data namapraktikan1[fitur].unique()}')
  values = array(data namapraktikan1[fitur])
  integer encoded = labels encoder.fit transform(values)
  transformed = jobs encoder.fit transform(integer encoded.reshape(len(i
    nteger encoded), 1))
  ohe df = pd.DataFrame(transformed,columns=jobs encoder.get feature
    names())
  data namapraktikan1 = pd.concat([data namapraktikan1, ohe df], axis=1
    ).drop([fitur], axis=1)
```

data namapraktikan1.head()

```
In [20]: print(data_ibnu.columns)
            fiturs = ['cuaca', 'suhu', 'kelembaban', 'berangin']
labels_encoder = LabelEncoder()
             jobs_encoder = OneHotEncoder(sparse=False)
             data_ibnu1 = data_ibnu.copy(deep=True)
              for fitur in fiturs:
                   print(f'{fitur}:{data_ibnu1[fitur].unique()}')
                   values = array(data_ibnu1[fitur])
                  values = array(uata_iniu[[IItur])
integer_encoded = labels_encoder.fit_transform(values)
transformed = jobs_encoder.fit_transform(integer_encoded.reshape(len(integer_encoded), 1))
ohe_df = pd.DataFrame(transformed,columns=jobs_encoder.get_feature_names())
data_ibnu1 = pd.concat([data_ibnu1, ohe_df], axis=1).drop([fitur], axis=1)
            Index(['cuaca', 'suhu', 'kelembaban', 'berangin', 'bermain'], dtype='object')
cuaca:['cerah' 'berawan' 'hujan']
suhu:['panas' 'sejuk' 'dingin']
kelembaban:['Tinggi' 'Normal']
berangin:['salah' 'benar']
Out[20]:
                 bermain x0 0 x0 1 x0 2 x0 0 x0 1 x0 2 x0 0 x0 1 x0 0 x0 1
              0 tidak 0.0 1.0 0.0 0.0 1.0 0.0 0.0 1.0 0.0 1.0
                   tidak 0.0 1.0 0.0 0.0 1.0 0.0 0.0 1.0 1.0 0.0
                       ya 1.0 0.0 0.0 0.0
                                                          1.0 0.0 0.0
                                                                                 1.0 0.0 1.0
                        ya 0.0 0.0 1.0 0.0 0.0 1.0 0.0 1.0 0.0
                    ya 0.0 0.0 1.0 1.0 0.0 0.0 1.0 0.0 0.0 1.0
```

6.2. Mengubah label pada kolom bermain dengan label encoder.

```
In [9]: integer_encoded = labels_encoder.fit_transform(data_ibnu1['bermain'])
main = pd.DataFrame(integer_encoded,columns=['label_bermain',])
data_ibnu1 = pd.concat([data_ibnu1, main], axis=1).drop(['bermain'], axis=1)
data_ibnu1.head()
```

Out[9]:

	x0_0	x0_1	x0_2	x0_0	x0_1	x0_2	x0_0	x0_1	x0_0	x0_1	label_bermain
0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	0
1	0.0	1.0	0.0	0.0	1.0	0.0	0.0	1.0	1.0	0.0	0
2	1.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	1
3	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	0.0	1.0	1
4	0.0	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	1.0	1

6.3. Menyiapkan fitur untuk prediksi dan label klasifikasi.

Data untuk prediksi yaitu data pada dataset kecuali kolom "bermain". Data untuk label klasifikasi yaitu data pada kolom "bermain".

```
y = data_namapraktikan1['label_bermain']
x = data_namapraktikan1.drop(columns=['label_bermain'])
```

print(f'variabel prediktor:{x.columns}')
print(f'label klasifikasi:{y.name}')

7. Membagi dataset menjadi data training dan data testing.

```
Data training = X_train dan y_train

Data testing = x_test dan y_test

Data training : data testing = 70 : 30 sehingga test size = 0.3
```

```
X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.3, random_stat
e=1)
size_xtrain = len(X_train)
size_xtest = len(X_test)
print(f'ukuran data training: {size_xtrain} ({size_xtrain+size_xtest})})')
print(f'ukuran data testing: {size_xtest} ({size_xtrain+size_xtest})})')
```

```
In [11]: X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.3, random_state=1)
    size_xtrain = len(X_train)
    size_xtest = len(X_test)
    print(f'ukuran data training: {size_xtrain} ({size_xtrain/(size_xtrain+size_xtest)})')
    print(f'ukuran data testing: {size_xtest} ({size_xtest/(size_xtrain+size_xtest)})')

    ukuran data training: 9 (0.6428571428571429)
    ukuran data testing: 5 (0.35714285714285715)
```

8. Melakukan split training dan testing model dengan membuat klasifier.

```
clf namapraktikan = DecisionTreeClassifier()
```

```
# proses training model
clf_namapraktikan = clf_namapraktikan.fit(X_train,y_train)

#proses testing model
y_pred = clf_namapraktikan.predict(X_test)
```

```
In [12]: clf_ibnu = DecisionTreeClassifier()

# proses training model
clf_ibnu = clf_ibnu.fit(X_train,y_train)

#proses testing model
y_pred = clf_ibnu.predict(X_test)
```

9. Membuat confusion matrix.

from sklearn.metrics import confusion_matrix

```
tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
print(f'confusion matrix')
```

```
print(f'{tp} | {fp}')
print(f'{fn} | {tn}')
```

```
In [13]: from sklearn.metrics import confusion_matrix

tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
print(f'confusion matrix')

print(f'{tp} | {fp}')
print(f'{fn} | {tn}')
```

confusion matrix
3 | 0
1 | 1

10. Melihat keakuratan model

print("Accuracy:",metrics.accuracy_score(y_test, y_pred))

11. Menampilkan decision tree

```
import numpy as np
from matplotlib import pyplot as plt
from sklearn import tree
```

```
n_nodes = clf_namapraktikan.tree_.node_count
children_left = clf_namapraktikan.tree_.children_left
children_right = clf_namapraktikan.tree_.children_right
feature = clf_namapraktikan.tree_.feature
```

```
threshold = clf_namapraktikan.tree_.threshold
node depth = np.zeros(shape=n nodes, dtype=np.int64)
is leaves = np.zeros(shape=n nodes, dtype=bool)
stack = [(0, 0)] # start with the root node id (0) and its depth (0)
while len(stack) > 0:
  # 'pop' ensures each node is only visited once
  node id, depth = stack.pop()
  node depth[node id] = depth
  # If the left and right child of a node is not the same we have a split
  # node
  is split node = children left[node id] != children right[node id] # If a split
node, append left and right children and depth to 'stack'
  # so we can loop through them
  if is split node:
    stack.append((children left[node id], depth + 1))
    stack.append((children right[node id], depth + 1))
  else:
    is leaves[node id] = True
print("The binary tree structure has {n} nodes and has "
   "the following tree structure:\n".format(n=n nodes))
for i in range(n nodes):
  if is leaves[i]:
    print("{space}node={node} is a leaf node.".format(
      space=node depth[i] * "\t", node=i))
  else:
    print("{space}node={node} is a split node: "
       "go to node {left} if X[:, {feature}] <= {threshold} "
       "else to node {right}.".format(
          space=node depth[i] * "\t",
          node=i,
          left=children left[i],
          feature=feature[i],
          threshold=threshold[i],
          right=children_right[i]))
```

12. Menampilkan plot decision tree

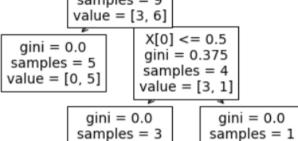
tree.plot_tree(clf_namapraktikan)
plt.show()

The binary tree structure has 5 nodes and has the following tree structure:

```
In [17]: tree.plot_tree(clf_ibnu)
    plt.show()

X[7] <= 0.5
    gini = 0.444
    samples = 9
    value = [3, 6]</pre>
```

value = [0, 1]



value = [3, 0]

13. Melakukan klasifikasi berdasarkan entropi

```
clf1 = DecisionTreeClassifier(criterion="entropy")
```

```
# Train Decision Tree Classifer clf1.fit(X_train,y_train)
```

#Predict the response for test dataset
y_pred = clf1.predict(X_test)

```
tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
print(f'confusion matrix')
print(f'{tp} | {fp}')
print(f'{fn} | {tn}')
```

#menampilkan akurasi model
print("Accuracy:",metrics.accuracy score(y test, y pred))

```
In [18]: clf1 = DecisionTreeClassifier(criterion="entropy")

# Train Decision Tree Classifer
clf1.fit(X_train,y_train)

#Predict the response for test dataset
y_pred = clf1.predict(X_test)

tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
print(f'confusion matrix')
print(f'{tp} | {fp}')
print(f'{fn} | {tn}')

#menampilkan akurasi model
print("Accuracy:",metrics.accuracy_score(y_test, y_pred))

confusion matrix
3 | 0
1 | 1
Accuracy: 0.8
```

Interpretasi output decision tree:

Interpretasi nya adalah jika nilai x lebih dari 0 maka akan dipisahkan, seterusnya akan begitu sampai nilai x tidak lebih dari 0, nilai gini index juga ketika sudah mulai dibagi, maka nilainya akan terus berkurang sampai terbagi rata.

ELEMEN KOMPETENSI II

Deskripsi:

Menerapkan prediksi menggunakan Decision Tree pada data Weather Nominal dataset 2.

Kompetensi Dasar:

Membuat prediksi pada Tree menggunakan data Weather Nominal dataset 2.

Latihan 1.2.1

Penjelasan Singkat:

Pada latihan ini anda akan diminta untuk membangun decision tree dan melakukan prediksi menggunakan library yang disediakan oleh python.

Langkah-Langkah Praktikum:

1. Disediakan data sebagai berikut :

Link dataset : https://www.kaggle.com/datasets/altruistdelhite04/loan-prediction-problem-dataset

2. Buatlah decision tree untuk dataset di atas menggunakan langkah-langkah pada elemen kompetensi 1. Tampilkan langkah-langkah pembuatannya beserta hasil decision tree.

```
from sklearn.model_selection import train_test_split #import train_test_split function from sklearn import metrics
In [16]: data_ibnu = pd.read_csv("D:/File Kuliah Semester 5/Penambangan Data/Prak-4/trainers.csv")
data_ibnu.head()
Out[16]:
        Gender Married Dependents Education Self_Employed Applicantincome Coapplicantincome LoanAmount Loan_Amount_Term Credit_History Property_Ai
         Male
                       1 Graduate
                                     No
                                              4583
                                                        1508.0
                                                                 128
                                                                            360
      2 Male Yes 0 Graduate Yes 3000 0.0 66
      3 Male Yes 0 Not No 2583 2358.0 120
                                                                            360
      4 Male No 0 Graduate No 6000 0.0 141 360 1 Urb
 In [17]: data_ibnu.info()
             <class 'pandas.core.frame.DataFrame'>
             RangeIndex: 614 entries, 0 to 613
             Data columns (total 12 columns):
                                            Non-Null Count Dtype
                  Column
                   ____
                                            _____
                  Gender 614 non-null object
Married 614 non-null object
Dependents 614 non-null int64
Education 614 non-null object
Self_Employed 614 non-null object
ApplicantIncome 614 non-null int64
              0
              1 Married
              2
               3
              5
                  CoapplicantIncome 614 non-null
                                                                 float64
              7
                  LoanAmount
                                     614 non-null
                                                                 int64
                   Loan_Amount_Term 614 non-null
                                                                 int64
              9 Credit_History 614 non-null
10 Property_Area 614 non-null
11 Loan_Status 614 non-null
                                                                int64
                                                                  object
                                                                  object
             dtypes: float64(1), int64(5), object(6)
             memory usage: 57.7+ KB
 In [22]: from numpy import array
          from numpy import argmax
          from sklearn.preprocessing import LabelEncoder
          from sklearn.preprocessing import OneHotEncoder
 In [18]: print(data_ibnu.columns)
          dtype='object')
```

```
data ibnu1.head()
                  300 376 117 71 173 46 228 308 236 570 380 296 156 103 45 65 53 62
                 218 178 239 465 148 199 149 153 162 230 86 234 246 500 186 119 107 209 208 243 40 250 311 400 161 196 324 157 145 181 26 211 9 205 36 61
               260 245 46 239 311 400 101 190 324 137 143 161 26 211 9 22 146 292 142 350 253]

Loan Amount Term:[360 120 240 480 100 180 60 300 36 84 12]

Credit History:[1 0]

Property_Area:['Urban' 'Rural' 'Semiurban']
   Out[28]:
                    In [29]: integer_encoded = labels_encoder.fit_transform(data_ibnu1['Loan_Status'])
               main = pd.DataFrame(integer_encoded,columns=['label_loan_status',])
data_ibnu1 = pd.concat([data_ibnu1, main], axis=1).drop(['Loan_Status'], axis=1)
               data_ibnu1.head()
  Out[29]:
                   x0_0 x0_1 x0_0 x0_1 x0_0 x0_1 x0_2 x0_3 x0_0 x0_1 ... x0_7 x0_8 x0_9 x0_10 x0_0 x0_1 x0_0 x0_1 x0_2 label_loan_status
               0.0 0.0 1.0 0.0 0.0
               In [32]: y = data_ibnu1['label_loan_status']
               x = data ibnu1.drop(columns=['label loan status'])
               print(f'variabel prediktor:{x.columns}')
               print(f'label klasifikasi:{y.name}')
                {\tt variabel \ prediktor:Index(['x0_0', 'x0_1', 'x0_0', 'x0_1', 'x0_0', 'x0_1', 'x0_2', 'x0_3', 'x0_0', 'x0_1', 'x0_
                           'x0_1',
                           'x0_6', 'x0_7', 'x0_8', 'x0_9', 'x0_10', 'x0_0', 'x0_1', 'x0_0', 'x0_1',
                        'x0_2'],
dtype='object', length=1023)
               label klasifikasi:label_loan_status
   In [33]: X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.3, random_state=1)
                    size_xtrain = len(X_train)
                    size_xtest = len(X_test)
                    print(f'ukuran data training: {size_xtrain} ({size_xtrain/(size_xtrain+size_xtest)})')
                    print(f'ukuran data testing: {size_xtest} ({size_xtest/(size_xtrain+size_xtest)})')
                    ukuran data training: 429 (0.6986970684039088)
                    ukuran data testing: 185 (0.30130293159609123)
```

```
In [34]: clf_ibnu = DecisionTreeClassifier()
                 # proses training model
                clf_ibnu = clf_ibnu.fit(X_train,y_train)
                 #proses testing model
                y_pred = clf_ibnu.predict(X_test)
In [35]: from sklearn.metrics import confusion matrix
                 tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
                print(f'confusion matrix')
                 print(f'{tp} | {fp}')
                print(f'{fn} | {tn}')
                 confusion matrix
                 115 | 33
                 9 | 28
In [36]: print("Accuracy:",metrics.accuracy_score(y_test, y_pred))
                Accuracy: 0.772972972973
In [37]: import numpy as np
                 from matplotlib import pyplot as plt
                from sklearn import tree
In [38]: n_nodes = clf_ibnu.tree_.node_count
    children_left = clf_ibnu.tree_.children_left
    children_right = clf_ibnu.tree_.children_right
    feature = clf_ibnu.tree_.feature
    threshold = clf_ibnu.tree_.threshold
          node_depth = np.zeros(shape=n_nodes, dtype=np.int64)
is_leaves = np.zeros(shape=n_nodes, dtype=bool)
stack = [(0, 0)]  # start with the root node id (0) and its depth (0)
while len(stack) > 0:
  # 'pop' ensures each node is only visited once
node_id, depth = stack.pop()
node_depth[node_id] = depth
              # If the left and right child of a node is not the same we have a split
              # node
is_split_node = children_left[node_id] != children_right[node_id]  # If a split node, append left and right children and de
# so we can loop through them
if is_split_node:
    stack.append((children_left[node_id], depth + 1))
    stack.append((children_right[node_id], depth + 1))
    stack.append((children_right[node_id], depth + 1))
              else:
is_leaves[node_id] = True
```

```
The binary tree structure has 149 nodes and has the following tree structure:

node=0 is a split node: go to node 1 if X[:, 1019] <= 0.5 else to node 12.

node=1 is a split node: go to node 2 if X[:, 570] <= 0.5 else to node 11.

node=2 is a split node: go to node 3 if X[:, 58] <= 0.5 else to node 10.

node=3 is a split node: go to node 4 if X[:, 345] <= 0.5 else to node 9.

node=4 is a split node: go to node 5 if X[:, 305] <= 0.5 else to node 8.

node=5 is a split node: go to node 6 if X[:, 513] <= 0.5 else to node 7.

node=6 is a leaf node.

node=7 is a leaf node.

node=9 is a leaf node.

node=10 is a leaf node.

node=11 is a leaf node.

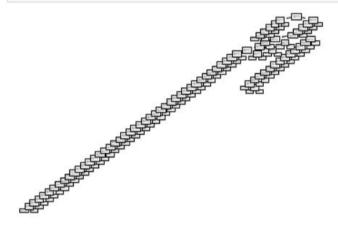
node=12 is a split node: go to node 13 if X[:, 318] <= 0.5 else to node 148.

node=13 is a split node: go to node 14 if X[:, 103] <= 0.5 else to node 146.

node=14 is a split node: go to node 15 if X[:, 712] <= 0.5 else to node 145.

node=16 is a split node: go to node 17 if X[:, 1021] <= 0.5 else to node 116.
```

```
In [39]: tree.plot_tree(clf_ibnu)
   plt.show()
```



```
In [40]: clf1 = DecisionTreeClassifier(criterion="entropy")

# Train Decision Tree Classifer
clf1.fit(X_train,y_train)

#Predict the response for test dataset
y_pred = clf1.predict(X_test)

tn, fp, fn, tp = confusion_matrix(y_test, y_pred).ravel()
print(f'confusion matrix')
print(f'{tp} | {fp}')
print(f'{fn} | {tn}')

#menampilkan akurasi model
print("Accuracy:",metrics.accuracy_score(y_test, y_pred))

confusion matrix
108 | 34
16 | 27
Accuracy: 0.7297297297297297
```

3. Berikan penjelasan tentang output yang muncul!

Interpretasi output decision tree:

Interpretasi nya adalah jika nilai x lebih dari 0 maka akan dipisahkan, seterusnya akan begitu sampai nilai x tidak lebih dari 0, nilai gini index juga ketika sudah mulai dibagi, maka nilainya akan terus berkurang sampai terbagi rata.

CEK LIST

Elemen	No Latihan	Penyelesaian				
Kompetensi	NO Latillali	Selesai	Tidak selesai			
1	1.1.1	✓				
2	1.2.1	✓				

FORM UMPAN BALIK

Elemen Kompetensi	Tingkat Kesulitan	Tingkat Ketertarikan	Waktu Penyelesaian dalam menit
Memahami decision tree	Sangat Mudah	Tidak Tertarik	
	Mudah	Cukup Tertarik	
	☐ ✓ Biasa	Tertarik	
	Sulit	✓ Sangat Tertarik	
	Sangat Sulit		
Mengimplementasika n decision tree.	Sangat Mudah	Tidak Tertarik	
	Mudah	Cukup Tertarik	
	☐ ✓ Biasa	Tertarik	
	Sulit	✓ Sangat Tertarik	
	Sangat Sulit		