# Pokok Bahasan V K-Nearest Neighbor (KNN).

Kode Pokok Bahasan: TIK.RPL03.004.00.01

# Deskripsi Pokok Bahasan:

Membahas bagaimana penerapan K-Nearest Neighbor untuk melakukan Klasifikasi.

No	Elemen Kompetensi	Indikator Kinerja	Jml Jam	Hal
1.	Menampilkan hasil Klasifikasi dari kasus yang diberikan.	Mampu melakukan analisis terhadap klasifikasi data dari diagram yangmuncul.	1	
2.	Melakukan perhitungan hasil prediksi dengan confusion matriks.	Melakukan perhitungan hasil prediksi dengan confusion matriks berdasarkan dataset pada studi kasus.	1	

# **TUGAS PENDAHULUAN**

Hal yang harus dilakukan dan acuan yang harus dibaca sebelum praktikum :

- 1. Menginstal Python pada PC masing-masing praktikan.
- 2. Menginstal Jupyter notebook pada PC masing-masing praktikan.
- 3. Menginstal library scikit-learn.

#### **DAFTAR PERTANYAAN**


- 1. Apa itu algoritma K-Nearest Neighbor? algoritma untuk melakukan klasifikasi terhadap objek dengan data pembe- lajaran yang jaraknya paling dekat dengan objek tersebut.
- 2. Apa kegunaan K-Nearest Neighbor?
- memiliki keunggulan dapat mengklasifikasikan data calon pegawai yang tidak diketahui dengan adanya data latih dan data uji. KNN dapat menprosedur yang berbasis matematis untuk mengevaluasi nilai kriteria-kriteria tersebut menjadi sebuah keterangan klasifikasi.
- 3. Sebutkan tahapan dari proses algoritma K-Nearest Neighbor!
- Langkah-1: Pilih nilai banyaknya tetangga K.
- Langkah-2: Hitung jarak dari jumlah tetangga K (bisa menggunakan salah satu metrik jarak, misalnya Euclidean distance)
- Langkah-3: Ambil tetangga terdekat K sesuai jarak yang dihitung.

#### **TEORI SINGKAT**

Algoritma K-Nearest Neighbor (K-NN) adalah sebuah metode klasifikasi terhadap sekumpulan data berdasarkan pembelajaran data yang sudah terklasifikasikan sebelumya. Termasuk dalam supervised learning, dimana hasil query instance yang

baru diklasifikasikan berdasarkan mayoritas kedekatan jarak dari kategori yang ada dalam K-NN

KNN, Dapat digunakan untuk tujuan klasifikasi, Tidak menyusun model atau mengekstrak aturan logika tertentu sebagai hasil dari analisis, Identikasi k buah individu tetangga terdekat dilakukan dengan terlebih dahulu menghitung jarak dari individu yang akan diduga dengan setiap individu yang ada pada gugus data training. Jika ini sudah dilakukan maka tinggal mencari k buah amatan yang jaraknya paling kecil. Penghitungan jarak dari dua amatan A dan B dapat menggunakan formula Euclid distance.



# LAB SETUP

Hal yang harus disiapkan dan dilakukan oleh praktikan untuk menjalankan praktikum modul ini.

- 1. Menginstall library yang dibutuhkan untuk mengerjakan modul.
- 2. Menjalankan Jupyter notebook.

#### ELEMEN KOMPETENSI I

#### **Deskripsi:**

Menampilkan hasil klasifikasi dari kasus yang diberikan.

# Kompetensi Dasar:

Menampilkan hasil Klasifikasi dari kasus yang diberikan.

#### Latihan 1.1.1

#### Penjelasan Singkat:

Pada latihan ini anda akan diminta melakukan analisis terhadap klasifikasi data dari diagram yang muncul.

#### Langkah- Langkah Praktikum:

1. import library yang dibutuhkan

import numpy as np import pandas as pd from matplotlib import pyplot as plt from sklearn.datasets import load\_breast\_cancer from sklearn.metrics import confusion\_matrix from sklearn.neighbors import KNeighborsClassifier from sklearn.model\_selection import train\_test\_split import seaborn as sns

```
In [1]: import numpy as np
    import pandas as pd
    from matplotlib import pyplot as plt
    from sklearn.datasets import load_breast_cancer
    from sklearn.metrics import confusion_matrix
    from sklearn.neighbors import KNeighborsClassifier
    from sklearn.model_selection import train_test_split
    import seaborn as sns
```

# 2. Menampilkan column features

breast cancer.feature names

#### 3. Menampilkan class target

breast cancer.target names

```
In [17]: breast_cancer.target_names
Out[17]: array(['malignant', 'benign'], dtype='<U9')</pre>
```

## 4. Menyeseleksi features column dan mngubah class target menjadi categorical

```
X = pd.DataFrame(breast_cancer.data, columns=breast_cancer.feature_names)
```

```
X = X[['mean area', 'mean compactness']]
```

y = pd.Categorical.from\_codes(breast\_cancer.target, breast\_cancer.target\_names)

y = pd.get\_dummies(y, drop\_first=True)

```
In [18]: X = pd.DataFrame(breast_cancer.data, columns=breast_cancer.feature_names)
X = X[['mean area', 'mean compactness']]
y = pd.Categorical.from_codes(breast_cancer.target, breast_cancer.target_names)
y = pd.get_dummies(y, drop_first=True)
```

#### 5. Split dataset

```
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
In [19]: X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

# 6. Memanggil dan menjalankan algoritma KNN

```
knn = KNeighborsClassifier(n_neighbors=5, metric='euclidean') knn.fit(X_train, y_train)
```

```
In [20]: knn = KNeighborsClassifier(n_neighbors=5, metric='euclidean')
knn.fit(X_train, y_train)

<ipython-input-20-52466d8b3ccf>:2: DataConversionWarning: A column-vector y was passed when a 1d array was expected. Please change the shape of y to (n_samples, ), for example using ravel().
knn.fit(X_train, y_train)
Out[20]: KNeighborsClassifier(metric='euclidean')
```


# 7. Melakukan prediksi dan menampilkan hasil prediksi

#### 8. Visualisasi dengan sns

```
sns.scatterplot(
    x='mean area',
    y='mean compactness',
    hue='benign',
    data=X_test.join(y_test, how='outer')
)

In [22]: sns.scatterplot(
    x='mean area',
    y='mean compactness',
    hue='benign',
    data=X_test.join(y_test, how='outer')
)
```


#### Out[22]: <matplotlib.axes.\_subplots.AxesSubplot at 0x1afa9f6a190>



# 9. visualisasi dengan matplotlib

plt.scatter(

Out[23]: <matplotlib.collections.PathCollection at 0x1afaa076fd0>



# 10. Menampilkan hasil Confusion matriks hasil prediksi confusion\_matrix(y\_test, y\_pred)

Interpretasi Confusion matriks:

# DIISISI

Interpretasi yang bisa dijelaskan adalah banyaknya data yang didapat dari berbagai sumber, maka pemrosesan dan analisis data yang efisien menjadi sulit, dikarenakan distribusi data yang tidak merata antar kelas.

# Elemen Komptensi 1.2.1

# **Tugas Laporan:**

- 1. Siapkan data iris.csv
- 2. Buka Jupyter Notebook
- 3. Mengimport module

```
from random import seed
from random import randrange
from csv import reader
from math import sqrt
```

4. Melakukan load file CSV

```
def load_csv(filename):
    dataset = list()
    with open(filename, 'r') as file:
        csv_reader = reader(file)
        for row in csv_reader:
            if not row:
                  continue
                  dataset.append(row)
    return dataset
```

5. Mengubah string menajdi float

```
def str_column_to_float(dataset, column):
    for row in dataset:
        row[column] = float(row[column].strip())
```

6. Mengubah string menjadi integer

```
def str_column_to_int(dataset, column):
    class_values = [row[column] for row in dataset]
    unique = set(class_values)
    lookup = dict()
    for i, value in enumerate(unique):
        lookup[value] = i
    for row in dataset:
        row[column] = lookup[row[column]]
    return lookup
```

7. Mencari nilai min dan max untuk setiap kolom

```
def dataset_minmax(dataset):
    minmax = list()
    for i in range(len(dataset[0])):
        col_values = [row[i] for row in dataset]
        value_min = min(col_values)
        value_max = max(col_values)
        minmax.append([value_min, value_max])
```

#### return minmax

```
8. Mengubah skala data
       def normalize_dataset(dataset, minmax):
               for row in dataset:
                      for i in range(len(row)):
                              row[i] = (row[i] - minmax[i][0]) / (minmax[i][1] -
       minmax[i][0]
9. Melakukan split data
def cross_validation_split(dataset, n_folds):
       dataset_split = list()
       dataset_copy = list(dataset)
       fold_size = int(len(dataset) / n_folds)
       for _ in range(n_folds):
               fold = list()
               while len(fold) < fold_size:
                      index = randrange(len(dataset_copy))
                      fold.append(dataset_copy.pop(index))
               dataset_split.append(fold)
       return dataset_split
10. Menghitung akurasi
def accuracy_metric(actual, predicted):
       correct = 0
       for i in range(len(actual)):
               if actual[i] == predicted[i]:
                      correct += 1
       return correct / float(len(actual)) * 100.0
11. Mengevaluasi algoritma menggunakan cross validation split
def evaluate_algorithm(dataset, algorithm, n_folds, *args):
       folds = cross_validation_split(dataset, n_folds)
       scores = list()
       for fold in folds:
               train_set = list(folds)
               train set.remove(fold)
               train_set = sum(train_set, [])
               test_set = list()
               for row in fold:
                      row_copy = list(row)
                      test_set.append(row_copy)
                      row_copy[-1] = None
               predicted = algorithm(train_set, test_set, *args)
               actual = [row[-1] for row in fold]
               accuracy = accuracy_metric(actual, predicted)
```

return scores

scores.append(accuracy)

```
12. Menghitung jarak Euclidean
```

```
\begin{split} \text{def euclidean\_distance(row1, row2):} \\ \text{distance} &= 0.0 \\ \text{for i in range(len(row1)-1):} \\ \text{distance} &+= (\text{row1[i] - row2[i]})**2 \\ \text{return sqrt(distance)} \end{split}
```

# 13. Menemukan neighors yang paling mirip

```
def get_neighbors(train, test_row, num_neighbors):
    distances = list()
    for train_row in train:
        dist = euclidean_distance(test_row, train_row)
        distances.append((train_row, dist))
    distances.sort(key=lambda tup: tup[1])
    neighbors = list()
    for i in range(num_neighbors):
        neighbors.append(distances[i][0])
    return neighbors
```

# 14. Membuat prediksi dengan neighbors

```
def predict_classification(train, test_row, num_neighbors):
    neighbors = get_neighbors(train, test_row, num_neighbors)
    output_values = [row[-1] for row in neighbors]
    prediction = max(set(output_values), key=output_values.count)
    return prediction
```

## 15. Algoritma KNN

```
def k_nearest_neighbors(train, test, num_neighbors):
     predictions = list()
     for row in test:
        output = predict_classification(train, row, num_neighbors)
        predictions.append(output)
    return(predictions)
```

#### 16. Menjalankan KNN

```
# Test the kNN on the Iris Flowers dataset
seed(1)
filename = 'knn.csv'
dataset = load_csv(filename)
for i in range(len(dataset[0])-1):
    str_column_to_int(dataset, i)
# convert class column to integers
str_column_to_int(dataset, len(dataset[0])-1)
# evaluate algorithm
n_folds = 5
num_neighbors = 5
scores = evaluate_algorithm(dataset, k_nearest_neighbors, n_folds, num_neighbors)
print('Scores: %s' % scores)
```

```
print('Mean Accuracy: %.3f%%' % (sum(scores)/float(len(scores))))
# define model parameter
num_neighbors = 5
# define a new record
row = [0.4, 0.1]
# predict the label
label = predict_classification(dataset, row, num_neighbors)
print('Data=%s, Predicted: %s' % (row, label))
```

# Screenshot tiap cell code:

```
In [1]: from random import seed
  from random import randrange
      from csv import reader
      from math import sqrt
In [16]:

def load_csv(filename):

dataset = list()

with open(filename, 'r') as file:

"csv_reader = reader(file)

"for row in csv_reader:

"if not row:

"dataset.append(row)

"return dataset
```

```
⊸return scores
 In [24]: def euclidean_distance(row1, row2):
         In [30]: # Test the kNN on the Iris Flowers dataset
       # evaluate algorithm
n folds = 5
        n_ious = 5

num_neighbors = 5

scores = evaluate_algorithm(dataset, k_nearest_neighbors, n_folds, num_neighbors)

print('Scores: %s' % scores)

print('Mean Accuracy: %.3f%%' % (sum(scores)/float(len(scores))))
       # define model parameter
num_neighbors = 5
# define a new record
row = [8.4, 0.1]
# predict the label
label = predict_classification(dataset, row, num_neighbors)
print('Data=%s, Predicted: %s' % (row, label))
        Scores: [75.0, 50.0, 75.0, 50.0, 50.0]
Mean Accuracy: 60.000%
Data=[0.4, 0.1], Predicted: 1
```

#### **CEK LIST**

Elemen	No Latihan	Penyelesaian		
Kompetensi		Selesai	Tidak selesai	
1	1.1.1	✓		
2	1.2.1	✓		

#### FORM UMPAN BALIK

Elemen Kompetensi	Tingkat Kesulitan	Tingkat Ketertarikan	Waktu Penyelesaian dalam menit
Menampilkan hasil Klasifikasi dari kasus yang diberikan. yang diberikan.	Sangat Mudah  Mudah  Biasa  Sulit  Sangat Sulit	☐ Tidak Tertarik ☐ Cukup Tertarik ☐ Tertarik ☐ ✓ Sangat	
Melakukan perhitungan hasil prediksi dengan confusion matriks.	Sangat Mudah  Mudah  Biasa  Sulit  Sangat Sulit	Tidak Tertarik  Cukup Tertarik  Tertarik  ✓ Sangat Tertarik	